

TP C++ n° 4 :

Analyse de logs apache

DURAND Bastien

FOURNIER Romain

9 février 2018

Table des matières

1	Cahier des charges et spécifications	2
2	Conception	2
3	Données	3
4	Réalisation	4
A	Manuel	4
B	Tests	5

Table des figures

1	Structure de données utilisée pour stocker et organiser les données extraites des logs	3
---	--	---

Introduction

1 Cahier des charges et spécifications

Nous avons créé un programme d'exploitation de fichiers log qui respecte les besoins formulés dans l'énoncé : -par défaut, l'outil affiche dans la console sous forme textuelle la liste des 10 documents les plus populaires par ordre décroissants. L'outil s'appelle en ligne de commande par la commande : `./analog [options] nomfichier.log`. -l'outil peut prendre 3 options en ligne de commande :

- `[-g nomfichier.dot]` produit un fichier au format Graphviz.
- `[-e]` permet d'exclure les ressources qui ont une extension js, image ou css.
- `[-t]` permet de ne prendre en compte que les hits dans un créneau horaire correspondant à l'intervalle [heure , heure+1[.

L'expression initiale des besoins étant un peu floue, nous y avons ajouté quelques spécifications :

- Par défaut, l'outil affiche dans la console sous forme textuelle la liste des 10 documents les plus populaires par ordre décroissants.
 - Si il y a moins de 10 documents consultés, l'outil donnera la liste de tous les documents classés par popularité.
 - Si la recherche n'a retourné aucun documents, l'outil donnera une réponse prédéfinie.
 - Si le fichier .log est vide, inexistant, mal formé ou non spécifié, l'outil affiche l'aide dans le terminal.
- `[-g nomfichier.dot]` produit un fichier au format Graphviz.
 - Pour les ressources n'ayant pas de referer (accès direct à la ressource), un noeud " - " représente les accès directs dans le graphe.
 - Si le nom du fichier .dot n'est pas spécifié, l'outil affiche l'aide dans le terminal.
 - Si un fichier du même nom existe déjà, une confirmation est demandée à l'utilisateur avant d'écraser le fichier.
- `[-e]` permet d'exclure les ressources qui ont une extension js, image ou css.
 - Si une ressource n'a pas d'extension, elle sera sélectionnée.
- `[-t]` permet de ne prendre en compte que les hits dans un créneau horaire correspondant à l'intervalle [heure, heure+1[.
 - L'outil devra aussi fonctionner si la plage horaire s'étend sur 2 jours.
 - Si l'heure n'est pas spécifiée ou au mauvais format, l'outil affiche l'aide dans le terminal.

2 Conception

Notre application ne comporte qu'une seule interface et une seule réalisation associée. En effet, nous avons décidé d'utiliser une structure de donnée de la STL pour gérer nos données. Nous n'avons donc pas eu à implémenter de classes supplémentaires. Nous avons séparé le fonctionnement de l'outil en différentes fonctions pour nous répartir le travail de manière efficace. Ainsi, nous avons établi l'architecture suivante :

- une fonction `genererCatalogue` qui crée et remplit la structure de données à partir du fichier log
- une fonction `genererGraphe` qui crée le fichier .dot à partir de la structure de données.

Remarque : notre structure de données étant déjà définie, nous avons commencé par ces deux fonctions que nous avons pu développer en même temps (en testant la fonction `genererGraphe` avec un jeu de données défini dans notre programme)

- une fonction `ajouterRessource` (appelée par la fonction `genererCatalogue`)

3 Données

Les données tirées de l'exploitation des logs seront stockées dans plusieurs conteneurs de la stl de type "unordered_map". A la différence d'une "map" ce conteneur ne stocke pas ses clés triées. Ainsi ce n'est pas sous forme d'arbre binaire rouge et noir qu'une "unordered_map" est implémentée mais sous la forme d'une table de hachage. Le cout en insertion ou recherche est en $O(1)$ en moyenne et $O(n)$ dans le pire des cas.

Les données extraites des logs sont des ressources et des referers. Voici la manière dont nous les stockons :

- chaque ressource est une clé dans une "unordered_map" "générale",
- clé étant associée à une valeur de type "unordered_map",
- les referers pointant sur une ressource sont clés de l'"unordered_map" liée à cette ressource,
- clé étant associée à une valeur de type int,
- cet entier désignant le nombre de fois que la ressource a été demandée via ce referer.

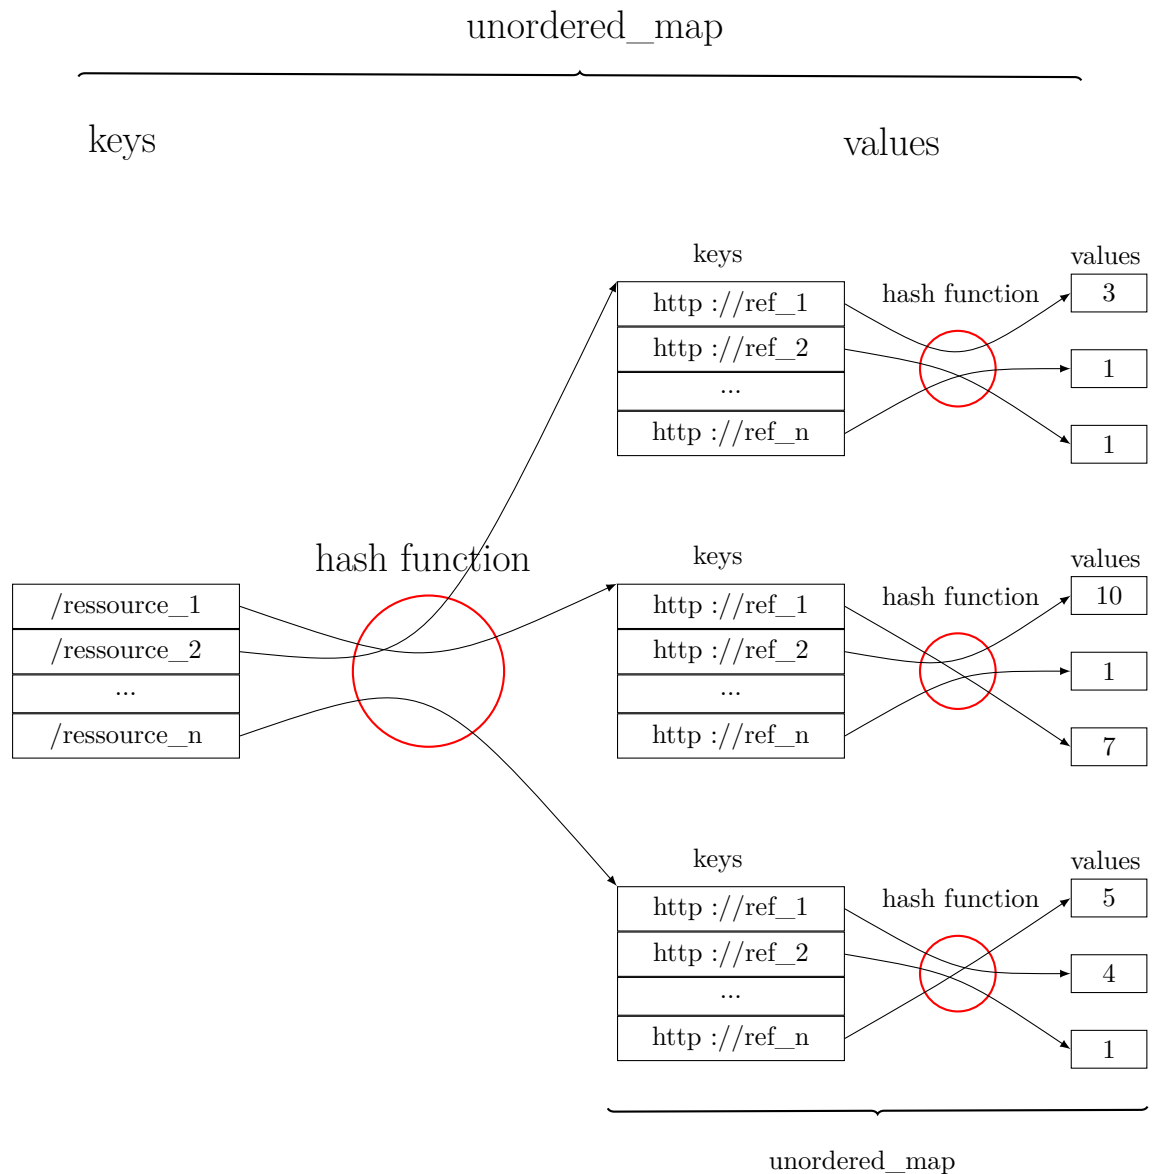


FIGURE 1 – Structure de données utilisée pour stocker et organiser les données extraites des logs

4 Réalisation

A Manuel d'utilisation

NOM

`analog`

SYNOPSIS

`analog` FILE [-e]... [-t HOURL]... [-g FILE]...

DESCRIPTION

`analog` permet d'analyser le fichier donné en entrée comme un enregistrement de logs apache.

Par défaut, sont donnés en sortie les 10 ressources les plus demandées sur le serveur. Seule les requêtes GET de code retour 200 sont analysées.

OPTIONS

-e

Ignore les ressources de type image : .png, .jpg, .bmp, .gif, .css, .js, .ico.

-t HOURL

Ignore les logs ne correspondant pas à l'intervalle [HOURL ; HOURL + 1].

-e FILE

Produit un fichier FILE qui est un graphe modélisant l'ensemble des ressources demandées via leur referer.

B Tests de validation

Afin de réaliser des tests tous en contrôlant les résultats fournis par le programme, un échantillon de logs a été créé. Le fichier "commentedSamples" contient ces lignes de logs triés par caractéristiques (status, heure, image, même ressource...). De cette manière il est plus facile de contrôler la sortie du programme qui verra ces logs triés comme des ensembles avec ou sans intersections. Le fichier "samples" est équivalent au fichier "commentedsamples" dont on a retiré les commentaires. C'est ce dernier fichier qui est donné en paramètre au programme.

Tests	Options	Justifications
1	aucune	Ce test appelle le programme sans options ni arguments. Il permet de valider l'affichage ou non du manuel d'utilisation.
2	aucune	Ce test appelle le programme sans options avec le fichier "samples" en paramètre. Nous contrôlons sur la sortie standard l'affichage des 10 ressources les plus demandées sans distinction des extensions ni des heures.
3	-e	Dans ce cas le programme est appelé avec l'option de filtrage des images "-e" avec le fichier "samples" en paramètre. Nous contrôlons sur la sortie standard l'affichage des 10 ressources les plus demandées et dont l'extension ne correspond pas à une image sans distinction des heures.
4	-t 15	L'option de sélection d'un créneau horraire "-t" est testée avec ce test qui appelle le programme avec l'option et l'heure 15 sur le fichier "samples". Nous contrôlons sur la sortie standard l'affichage des 10 ressources les plus demandées et dont l'heure du log est comprise sur le créneau [15;16] sans distinction de l'extension.
5	-t 15 -e	Ce test appelle le programme avec deux options combinées "-t" et "-e" sur le fichier "samples". Nous contrôlons sur la sortie standard l'affichage des 10 ressources les plus demandées avec filtrage des images et dont l'heure du log est comprise sur le créneau [15;16].
6	-g testdot	Ici le programme est appelé avec l'option "-g" et la chaîne "testdot" sur le fichier "samples". Avec cette option le programme doit générer un fichier de type "dot" et dont le nom est celui de la chaîne donnée "testdot". Le fichier généré décrit un graphe modélisant l'ensemble des liens entre ressources et referers contenus dans les logs. Nous contrôlons sur la sortie standard l'affichage des 10 ressources les plus demandées et la création du fichier "dot" sans distinction des extensions et des heures.